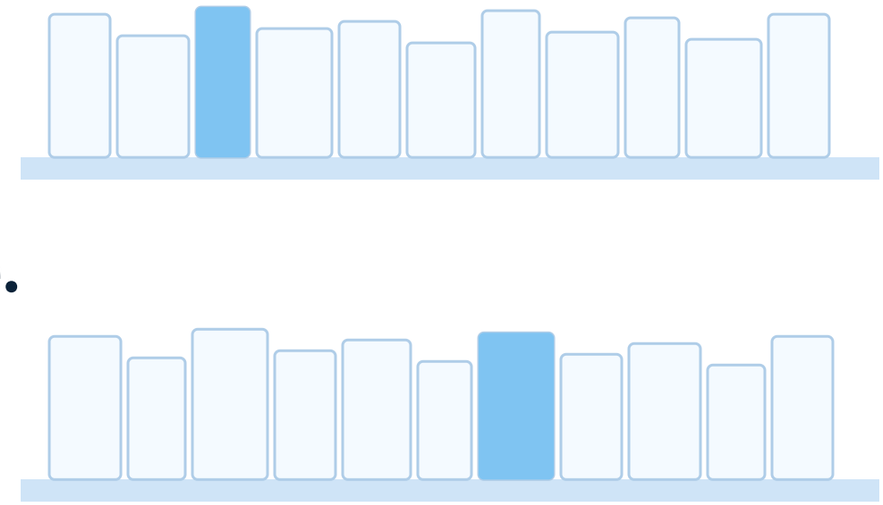
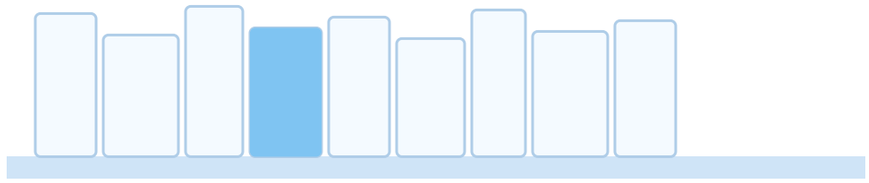
Eigenes Brain bauen

Der Bauplan zum Vortrag, BCD-Gruppe, 30.10.2026



Ein Thema, zwanzig Bücher, ein Wochenende.



20 BÜCHER · 1 BRAIN

Christoph Erler · Erler Ventures

Begleitdeck zum Repo brain-bauplan

Ergebnis

ZWECK Eine durchsuchbare Bibliothek zu eurem Thema. Claude schlägt nach, statt zu raten, und nennt zu jeder Antwort Buch und Seite.

- **Durchsuchbar:** eure 20 Bücher in einer Bibliothek
- **Nachgeschlagen:** Claude liest, bevor es antwortet
- **Belegt:** jede Antwort mit Buch und Seite

8
Brains im System
CHRIS' SYSTEM

12.000
Quellen
CHRIS' SYSTEM

1,03 Mio.
Textstellen
CHRIS' SYSTEM

Ohne Quelle ist eine Antwort eine Meinung

Die Zahlen oben stammen aus meinem System. Euer erstes Brain ist kleiner.

DER WEG

Ablauf

ZWECK Sechs Schritte, feste Reihenfolge. Wer bei Schritt 3 anfängt, hat kein Thema und keine Bücher.

01
Thema
Ein Fachgebiet, bei dem ihr heute googelt und zweifelt.

02
Quellen
20 Standardwerke, gekauft oder frei und legal.

03
Einlesen
Text mit Seitenzahlen, in Schnipsel geschnitten.

04
Index
Jeder Schnipsel bekommt Zahlencode und Wortverzeichnis.

05
Anschluss
Claude greift per MCP auf den Index zu.

06
Messen
Zehn Fragen, deren Antwort ihr kennt.

Schritt 6 führt zurück auf Schritt 2

Zeigt die Messung eine Lücke, kauft ihr das nächste Buch.

Hardware

ZWECK Drei Stufen. Alles läuft ohne Grafikkarte. Mit Grafikkarte wird es schneller und der Reranker brauchbar.

STUFE 1 · OHNE GPU

Geht, mit Abstrichen

< 1 s

- Suche: 0,94 Sekunden je Frage
- Reranker unbrauchbar: 127 Sekunden
- Kontextsätze aus der Cloud

GEMESSEN: 4 KERNE, 15 GB RAM

STUFE 2 · LAPTOP, 8 GB VRAM

Reicht für den Bau

25 bis 35

- Kontextsätze je Minute
- Modell: 7B, 4,7 GB
- 14B passt nicht (9 GB Modell)

EMBEDDING UND RERANKER AUF DER GPU

STUFE 3 · STAND-PC, 24 GB VRAM

Alles lokal

rund 20 Min.

- Vollbau, 400.000 Chunks
- Kontextsätze: 74 bis 80 je Minute
- Modell: 14B, 13,5 GB VRAM

GEMESSEN AM 30.10.2026

Richtpreis: die Grafikkarte, rund 2.000 Euro

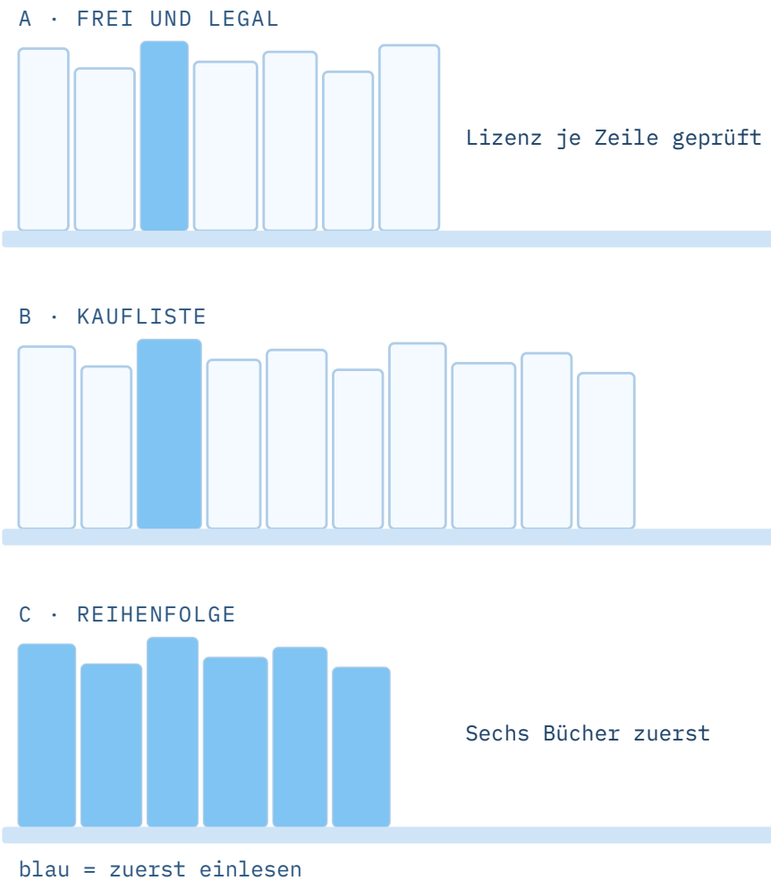
Python 3.11 mit Torch cu128. Häufigster Fehler: Torch ohne GPU-Unterstützung.

Quellen

ZWECK Euer Fachgebiet wird zu 20 Standardwerken. Etwa die Hälfte der Liste liegt frei und legal im Netz, der Rest wird gekauft.

A	**Frei und legal**	Lizenz je Zeile geprüft
B	**Kaufliste**	Titel, Verlag, ISBN, Shop, Preis
C	**Reihenfolge**	Stufe 1 zuerst, Rest nach Messung
Start	**Kleinstart: sechs Bücher**	Ein Nachmittag, und das Brain ist nützlich
Lücke	**Lückenanalyse**	Frage: ist das wirklich alles?

Aktuelle Auflage kaufen, nicht die erste



QUELLEN BESCHAFFEN

Beschaffung

ZWECK Kauft eine eigene Kopie, am besten DRM-frei. Rund 30 Euro je Titel, 20 Bücher kosten 600 bis 1.100 Euro.

Verlage DRM-frei | O'Reilly über ebooks.com | Kindle | Akademische Verlage | Print plus Scan | Amtliche Werke | Open Access

REGEL

- Eigene Kopie
- Lokal indexiert
- Keine Weitergabe
- Vermerk im Register

KOSTEN

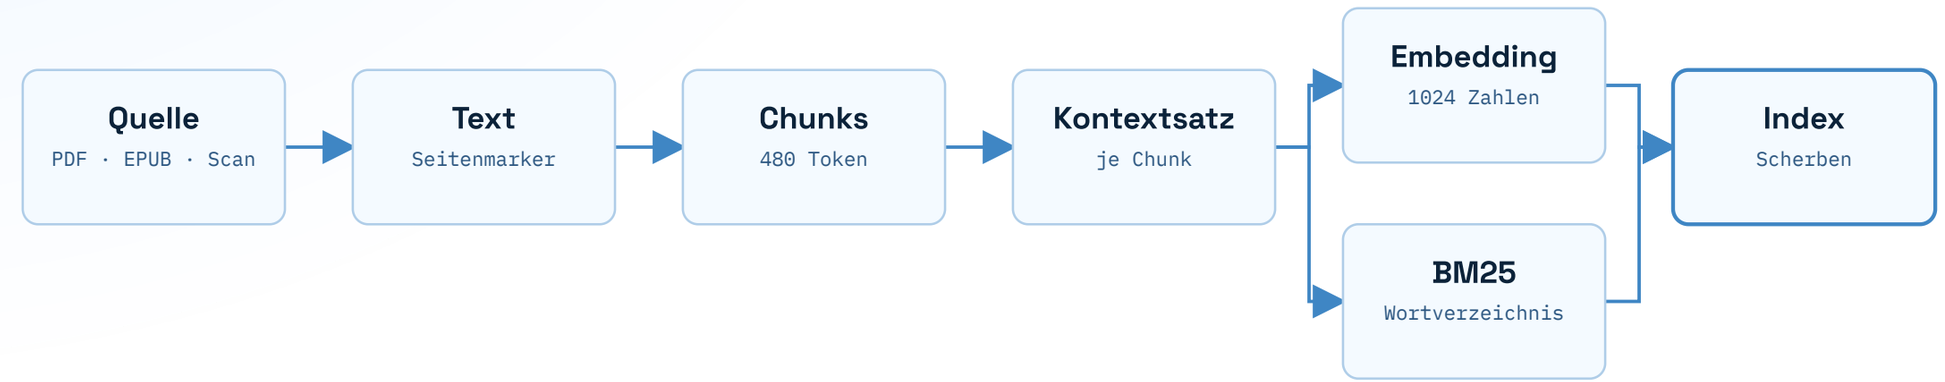
- Rund 30 € je Titel
- 20 Bücher: 600 bis 1.100 €
- Amtliche Werke und Open Access: 0 €
- NC- und ND-Lizenzen: bleiben lokal

Geschützter Volltext gehört nie in ein Repo oder auf ein geteiltes Laufwerk

Print plus Scan: rechtliche Prüfung offen, vorher klären.

Einlesen

ZWECK Jedes Buch wird in Chunks geschnitten, etwa eine Buchseite je Chunk. Jeder bekommt einen Satz, woher er stammt, und einen Zahlencode. Einmal pro Buch.



Seitenmarker sind Pflicht

Ohne sie gibt es keine Seitenzahl im Treffer.

Suche

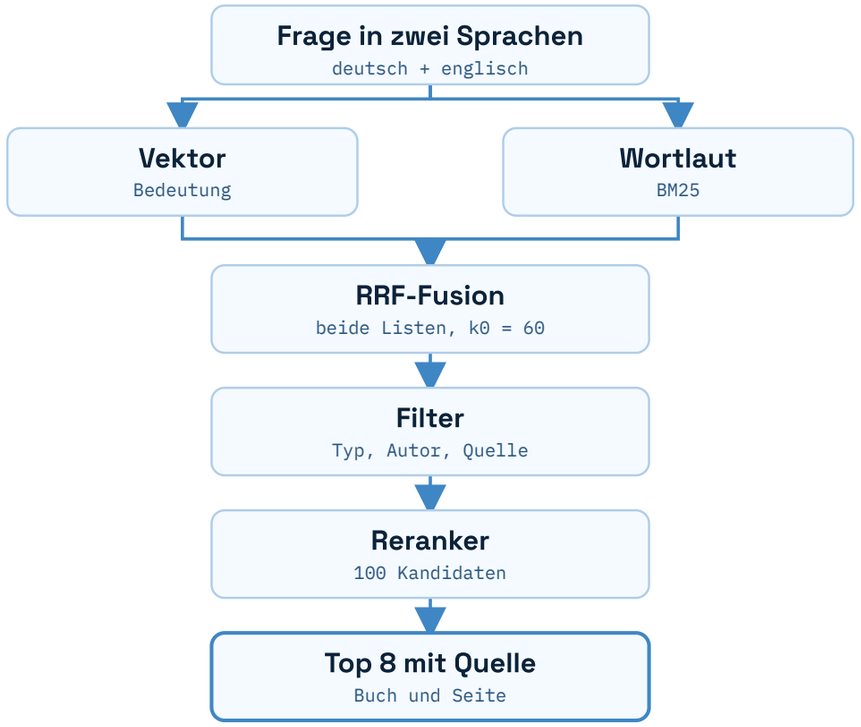
ZWECK Die Frage geht zweisprachig in Vektor- und Wortsuche. Eine Fusion mischt beide Listen, der Reranker sortiert die besten 100 neu.

0 von 15

Gold-Treffer mit deutscher Frage in der Wortsuche

94 %

mit englischen Stichwörtern. Der Index ist zu 92,7 Prozent englisch



bge-reranker-v2-m3 · unter 1 Sekunde ohne Reranker

Deshalb stellt Claude jede Frage zweimal

Deutsch und Englisch, beides geht mit.

TRAINIEREN HEISST MESSEN

Messung

ZWECK Es wird kein Modell trainiert. Ihr baut Testfragen und messt jede Änderung dagegen. Nur was besser misst, bleibt.

01 **Goldset**
60 Fragen mit erwarteter Quelle

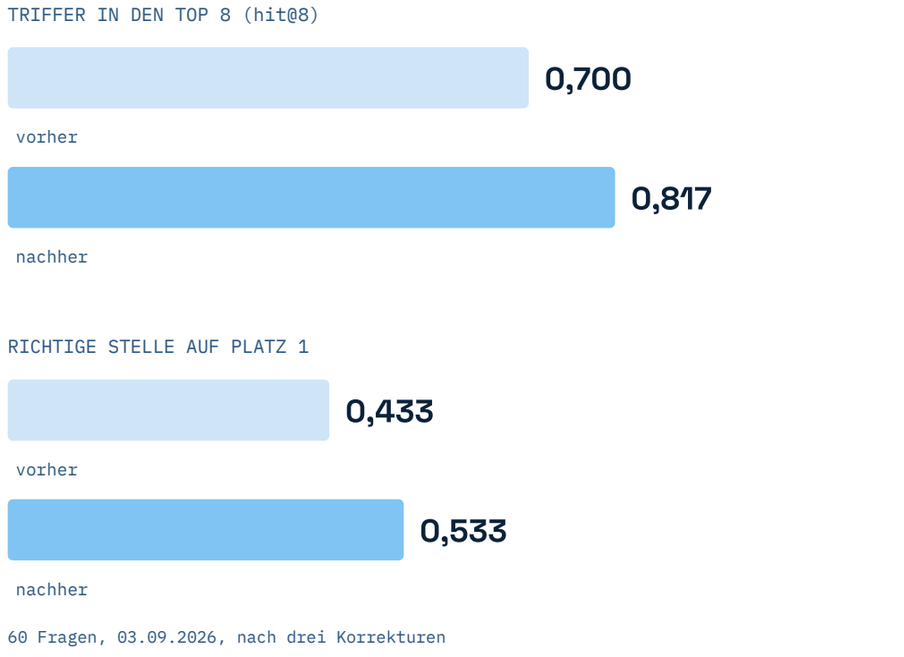
02 **Kennzahlen**
hit@8, Platz 1, MRR

03 **Gate**
Kein Verlust über 0,02 bei hit@8

04 **Ratsche**
Bester Stand wird gespeichert, Rückschritt bricht ab

Schwäche: das Goldset stammt aus eigenen Treffern

Ein getrenntes Prüfset gibt es nicht. Empfehlung: Holdout.



JE BRAIN GEMESSEN

Reranker

ZWECK Der Reranker sortiert die Treffer neu. In einem Brain hilft er, in zwei anderen schadet er.

BRAIN	RERANKER	MESSUNG	FRAGEN
CCG	an	hit@8 0,700 ohne, 0,817 mit	60
CFO	aus	MRR 0,814 ohne, 0,736 mit	80
Psy	aus	MRR 0,945 ohne, 0,857 mit	61

Dieselbe Komponente hilft hier und schadet dort

Deshalb messen, nicht glauben. Für vier weitere Brains liegt keine Messung vor.

ANSCHLUSS AN CLAUDE

MCP

ZWECK MCP ist die Steckdose, über die Claude euren Index abfragt. Der Server hat vier Werkzeuge und läuft lokal.

suchen

Frage in den Index, acht Treffer mit Buch und Seite

stelle

Nachbartext einer Fundstelle holen

bruecken

Querverweise zwischen Quellen

deckung

Was der Index vom Register kennt

WAS DEN RECHNER VERLÄSST

- Die Frage
- Die acht Stellen
- Nichts sonst

SKILL-REGELN

- Frage zerlegen
- Immer auch frage_en
- Nullmeldung heißt nicht: fehlt

Kommt nichts zurück, prüft Claude erst das Register

`Eine Suche ohne Treffer beweist keine Lücke.`

ZWEI ARTEN ZU SUCHEN

Tiefe

ZWECK Nachschlagen braucht eine Suche. Eine echte Recherche zerlegt die Frage und prüft jede Teilfrage einzeln.

SHALLOW

Eine Suche, acht Treffer

- Frage direkt in den Index
- Antwort aus acht Stellen
- Reicht zum Nachschlagen

SEKUNDEN

DEEP RESEARCH

Sieben Teilfragen, 58 Treffer

- Je Teilfrage eine Suche, mehrere Brains
- Zwei Nachbarstellen nachgeholt
- Sicherheitsstufen: sicher, mittel, unsicher
- Quellenliste mit Chunk-Nummern

BEISPIEL: WEGZUG DEUTSCHLAND NACH ÖSTERREICH

Rauschen wird sichtbar aussortiert, nicht still weggelassen

Ergebnis im Beispiel: Das Datum entscheidet. Fundstelle: § 6 Abs. 2 AStG.

Kosten

ZWECK Einmal rund 2.000 Euro für die Grafikkarte, laufend das Abo. Eure Bücher bleiben auf der Platte.

POSTEN	BETRAG
Grafikkarte, einmalig	2.000 €
Claude-Abo	rund 200 € im Monat
Einlesen mit Cloud-Modell	rund 7 $ je Stapel
Einlesen lokal	0 $
Bücher	rund 30 € je Titel

BLEIBT AUF DER PLATTE

- Bücher und Index
- Suche läuft lokal

GEHT RAUS

- Pro Frage: Frage plus acht Stellen an Claude
- Kontextsätze in der Cloud: Chunk-Text geht mit

Vertrauliches Material: Kontextsätze lokal erzeugen

Zeit, Strom und Rest-PC sind nicht eingerechnet.

DAS WOCHENENDE

Zeitplan

ZWECK Drei Tage, je ein Ergebnis. Die Zeiten sind Richtwerte und nicht gemessen.

Freitag

THEMA UND TITEL

1 Std.	Thema wählen: wo googelt ihr und zweifelt
1 Std.	20 Titel auflisten, Listen A, B, C
30 Min.	Sechs Bücher für den Start markieren

ABBRUCH

Keine 20 Titel nennbar: Thema zu breit, enger fassen

Samstag

BESCHAFFEN UND BAU

2 Std.	Bücher kaufen und laden
1 Std.	Text mit Seitenmarkern, Register füllen
1 bis 3 Std.	Kontextsätze, Embedding, Index bauen

ABBRUCH

Seitenzahlen fehlen oder Register passt nicht zum Index: erst reparieren

Sonntag

ANSCHLUSS UND TEST

1 Std.	MCP anschließen
1 Std.	Zehn Prüffragen, Antwort bekannt
30 Min.	Erste echte Frage stellen

ABBRUCH

Prüffrage ohne richtige Stelle in den acht Treffern: Buch nachkaufen

Nicht klüger.
Belesener.

Bauplan, Code und Kapitel im Repo brain-bauplan.

Christoph Erler · Erler Ventures
BCD-Gruppe · 30. Oktober 2026